# QuickSelect

# **Algorithm Description**

#### Naive QuickSelect

在计算机科学中,**快速选择**(英语: Quickselect) 是一种从无序列表找到第 k 小元素的选择算法。它从原理上来说与快速排序有关。与快速排序一样都由托尼·霍尔提出的,因而也被称为霍尔选择算法。同样地,它在实际应用是一种高效的算法,具有很好的平均时间复杂度,然而最坏时间复杂度则不理想。快速选择及其变种是实际应用中最常使用的高效选择算法。

速选择的总体思路与快速排序一致,选择一个元素作为基准来对元素进行分区,将小于和大于基准的元素分在基准左边和右边的两个区域。不同的是,快速选择并不递归访问双边,而是只递归进入一边的元素中继续寻找。这降低了平均时间复杂度,从O(nlogn)至O(n),不过最坏情况仍然是 $O(n^2)$ 。快速排序一样,快速选择一般是以原地算法的方式实现,除了选出第k小的元素,数据也得到了部分地排序。

大部分情况下,上面提到的情况可以通过随机选取基准来解决,但是少部分情况下(比如所有元素全都相等的时候),最坏情况仍为 $O(n^2)$ 。因此我们需要其他的办法来解决这个问题。


## Modified QuickSelect(BFBRT)

解决上面最坏情况的办法是**通过某种选取基准的方法,使得每次划分子数组的长度都能至少以某个固定比例缩小。** 这里我们采取的方法是:

- 1. 将 个输入元素划分成  $\frac{n}{5}$  个组,每组  $\frac{5}{5}$  个元素,可能有一个组少于  $\frac{5}{5}$  个元素。用任意一种排序算法,将每组的元素排好序,并取出每组的中位数,共  $\frac{n}{5}$  个。
- 2. 递归调用select来找出这  $\frac{n}{k}$ 个元素的中位数。如果是偶数,就找它的 2 个中位数中较大的一个。
- 3. 以这个元素作为划分基准。

这个算法在最坏情况下的复杂度也达到了 O(n),它的正式名字叫做**BFBRT**算法,这个名字来自它的五个提出者 ————Blum、Floyd、Pratt、Rivest、Tarjan。

关于这个算法的执行过程, 我找到这样一张图片, 可以清晰地描述:



# **Implementation**

虽然我们的project只要求我们实现线性时间的选择算法,但这里我们两种算法都实现一下,以便比较。

### **Naive QuickSelect**

这里的基准随机产生,毕竟这也是一个优化之处。另一个优化的地方在于,如果这个数组过小(不超过75个元素),那么我们选择直接对它排序。

```
def select_random_pivot(array, k):
    ...
    The implementation of QuickSelect algorithm to select the k'th smallest element.
    Here the pivot is chosen randomly.
    ...

# If the array is short, terminate the recursion and return the
    # value without partitioning.
    if len(array) <= 75:
        array.sort()
        return array[k-1]

# Randomly choose a pivot point.
    pivot_idx = random.randint(0, len(array) - 1)
    pivot = array[pivot_idx]

# divide into three parts: little, great, and equal.
    array_lt = []
    array_gt = []
    array_eq = []

for item in array:</pre>
```

```
if item < pivot:
    array_lt.append(item)
elif item > pivot:
    array_gt.append(item)
else:
    array_eq.append(item)

if k <= len(array_lt): # in the little part
    return select_random_pivot(array_lt, k)
elif k <= len(array_lt) + len(array_eq): # in the equal part
    return array_eq[0]
else: # in the great part
    normalized_k = k - (len(array_lt) + len(array_eq))
    return select_random_pivot(array_gt, normalized_k)</pre>
```

```
# simple test

# case 1: (less than ten)
a = [14,5,3,7,4,2,9,7]
print(select_random_pivot(a, 3))

# case 2:
import numpy as np
from numpy import random

a = np.random.randint(0, 100, size = 100)
b = sorted(a)
print(b[87-1])
print(select_random_pivot(a,87))
```

```
4
83
83
```

### **BFBRT**

```
for i in range(num medians):
```

```
# simple test
a = np.random.randint(0, 1000, size = 1000)
b = sorted(a)
print(b[45-1])
print(select_median_of_medians_pivot(a, 45))
```

```
43
43
```

### **Test of correctness**

我们在从 10 到 100000 大小的数据集上进行测试,每个数据集上选取 5 个位置。

#### correct test (1

```
Same as built-in method? True
```

```
Same as built-in method? True
Same as built-in method? True
Same as built-in method? True
----- dataset division ------
Same as built-in method? True
```

#### correct\_test(0)

```
Same as built-in method? True
Same as built-in method? True
Same as built-in method? True
----- dataset division ------
Same as built-in method? True
```

于是我们验证了这两个算法的正确性。

# **Performance measurement**

与往常一样,我们被要求分析**最坏情况和平均情况**下的时间复杂度。有趣的是,BFBRT算法之所以被提出,正是因为它的最坏情况也是O(n)。至于随机选择基准的快速选择,由于其随机性,也很难出现所谓的最坏情况(我能想到的只有所有元素都相同的情况,但老师在群里提到元素应该各异,那么这个情况也不存在了)。

但是这些优化都是针对**未优化的快速选择(即固定基准)可能出现的最坏情况**所做的优化,目的是解决这种情况下可能出现的最坏情况的问题。因此,我们这里选取的最坏情况的数据,是针对**未优化版本的快速选择**选取的;也就是有序的数据。这种情况下,选择第n小的元素(也就是最大元素)递归最深。

而平均情况下,数据随机产生,所选择的 k 也随机产生。

#### Ordered datasets

```
return runtime
```

```
random_time = ordered_measure(1)
random_time
```

```
[0.0005013942718505859,

0.004511833190917969,

0.010025978088378906,

0.023563861846923828,

0.06370806694030762,

0.0811769962310791,

0.15189313888549805,

0.22911405563354492,

0.32886695861816406,

1.6463472843170166,

3.300302743911743,

3.7286229133605957]
```

```
median_time = ordered_measure(0)
median_time
```

```
[0.0,

0.006122112274169922,

0.01897907257080078,

0.05464577674865723,

0.10427737236022949,

0.2561826705932617,

0.532416582107544,

1.0408177375793457,

1.3004586696624756,


8.180448532104492,

14.199047088623047,

19.182743787765503]
```

```
from matplotlib.pyplot import *
% matplotlib inline

data_size = [50, 100, 200, 500, 1000, 2000, 5000, 8000, 10000, 50000, 80000, 100000]
plot(data_size, random_time, label = 'random pivot')
plot(data_size, median_time, label = 'median of medians pivot')
plot(data_size, random_time, 'r*')
plot(data_size, median_time, 'b+')
legend(loc = 'best')
xlabel('dataset size')
ylabel('running time(s) per 100 loops')
title('Performance on ordered datasets')
grid()
```



#### Random datasets

```
def random_measure(flag):
    '''
    Performance on ordered datasets.
    when flag == 1, we measure select_random_pivot,
    when flag == 0, we measure select_median_of_medians_pivot.
    '''

    runtime = []

# generate the datasets
data_size = [50, 100, 200, 500, 1000, 2000, 5000, 8000, 10000, 50000, 80000, 100000]

for i in data_size:
    data = list($500000*np.random.random(i))
    if flag == 1:
        tic = time.time()
        k = random.randint(0, i + 1)
        for j in range(100):
            x = select_random_pivot(data, k)
        toc = time.time()
        runtime.append(toc - tic)

elif flag == 0:
    tic = time.time()
    for j in range(100):
        x = select_median_of_medians_pivot(data, k)
        toc = time.time()
        runtime.append(toc - tic)

return runtime
```

```
rand_time = random_measure(1)
rand_time
```

```
[0.0,

0.006518840789794922,

0.01403498649597168,

0.042613983154296875,

0.08823466300964355,

0.14087462425231934,

0.25220441818237305,

0.3933427333831787,

0.46172571182250977,


2.392361640930176,

3.1057281494140625,

4.881023645401001]
```

```
mid_time = random_measure(0)
```

```
data_size = [50, 100, 200, 500, 1000, 2000, 5000, 8000, 10000, 50000, 80000, 100000]
plot(data_size, rand_time, label = 'random pivot')
plot(data_size, mid_time, label = 'median of medians pivot')
plot(data_size, rand_time, 'r*')
plot(data_size, mid_time, 'b+')
legend(loc = 'best')
xlabel('dataset size')
ylabel('running time(s) per 100 loops')
title('Performance on random datasets')
grid()
```




可以看出,两种算法基本都是线性的,所以我们验证了算法复杂度为O(n)。

可以看出,随机选取基准还要更快些。这是因为随机选取基准的情况已经很难出现所谓最坏情况了,在这样的前提下,BFBRT花费了更多的时间在选取基准上。因此这是可以理解的。

再比较一下两种情况下的BFBRT的情况。

```
plot(data_size, mid_time, label = 'random datasets')
plot(data_size, mid_time, 'b+')
plot(data_size, median_time, label = 'ordered datasets')
plot(data_size, median_time, 'r*')
legend(loc = 'best')
xlabel('dataset size')
ylabel('running time(s) per 100 loops')
title('random/ordered datasets comparison')
grid()
```



两种情况差距不大,因此我们可以说,BFBRT已经解决了这个最坏情况的问题。

## Conclusion

- 1. BFBRT的最差情况也是 O(n) 的,这是一个效率非常稳定的线性算法。
- 2. BFBRT需要选取中位数的中位数时需要一些开销,因此在大多数情况下要比随机选取基准要慢;事实上,《算法导论》中提到,一些计算机科学家们给出了一个寻找中位数所需的比较次数的下界  $(2+\epsilon)n$  次,因此相对来说还是开销较大的。从另外一方面来说,它的实现也要比随机选取基准更加复杂。尽管随机选取的最坏情况仍然是  $O(n^2)$ ,但这种情况发生的概率非常小。因此我认为,在大多数情况下,使用随机选取基准会是更好的选择。